

Kapitel 1 - Das einfache lineare Regressionsmodell

Einfaches lineares Regressionsmodell

Das **einfache lineare Regressionsmodell** hat die Form

$$Y_i = \beta_0 + \beta_1 x_i + \varepsilon_i, \quad i = 1, \dots, n$$

für ein festes numerisches x_i und $\varepsilon_i \sim \mathcal{N}(0, \sigma^2)$. Beachte, dass per Definition gilt $Y_i | x_i \sim \mathcal{N}(\beta_0 + \beta_1 x_i, \sigma^2)$

Kleinste Quadrate (KQ) Schätzer

Wir schätzen die Parameter (β_0, β_1) durch

$$(\hat{\beta}_0, \hat{\beta}_1) = \arg \min_{(\beta_0, \beta_1)} \sum_{i=1}^n (Y_i - (\beta_0 + \beta_1 x_i))^2 \quad (1)$$

und nennen $(\hat{\beta}_0, \hat{\beta}_1)$ den **KQ-Schätzer von (β_0, β_1)** und $\hat{\varepsilon}_i := Y_i - (\hat{\beta}_0 + \hat{\beta}_1 x_i)$ die **Residuen**.

Existenz und Berechnung vom KQ Schätzer

Der KQ-Schätzer existiert und ist eindeutig, falls $\sum_{i=1}^n (x_i - \bar{x})^2 \neq 0$. Dieser lässt sich berechnen als

$$\hat{\beta}_1 = \frac{S_{xY}}{S_x^2} = \frac{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})(Y_i - \bar{Y})}{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2}$$
$$\hat{\beta}_0 = \bar{Y} - \hat{\beta}_1 \bar{x}.$$

Durch differenzieren von der Gleichung (1) erhält man $(\hat{\beta}_0, \hat{\beta}_1)$ als Lösung der **Normalengleichungen**

$$\sum_{i=1}^n \hat{\varepsilon}_i = 0$$
$$\sum_{i=1}^n \hat{\varepsilon}_i x_i = 0$$

Interpretation der Modellparameter

Für $Y_i = \beta_0 + \beta_1 x_i + \varepsilon_i$, $i = 1, \dots, n$ mit $E(Y_i | x_i) = \beta_0 + \beta_1 x_i$ gilt,

- wenn x um eine **Einheit** steigt, dann steigt Y **im Erwartungswert** um β_1 Einheiten.
- Es gilt $\beta_0 = E(Y | X = 0)$.
- Der Parameter σ die erwartete Abweichung der Y_i -Werte von der Regressionsgerade an.

Eigenschaften des KQ-Schätzers

Gegeben dem einfachen linearen Modell, gilt für den KQ-Schätzer $(\hat{\beta}_0, \hat{\beta}_1)$

- Erwartungstreue: $E(\hat{\beta}_0, \hat{\beta}_1) = (\beta_0, \beta_1)$.
- $V(\hat{\beta}_1) = \frac{\sigma^2}{n S_x^2}$ und $V(\hat{\beta}_0) = \sigma^2 \left(\frac{1}{n} + \frac{\bar{x}^2}{n S_x^2} \right)$.
- $(\hat{\beta}_0, \hat{\beta}_1)$ ist der maximum-likelihood Schätzer.

Schätzer für σ^2

Gegeben dem einfachen linearen Modell mit $\varepsilon_i \sim \mathcal{N}(0, \sigma^2)$, gilt

$$\hat{\sigma}^2 := \frac{1}{n-2} \sum_{i=1}^n \hat{\varepsilon}_i^2$$

ist ein erwartungstreuer Schätzer von σ^2 und

$$\frac{n-2}{\sigma^2} \hat{\sigma}^2 \sim \chi_{n-2}^2.$$

Der KQ-Schätzer $(\hat{\beta}_0, \hat{\beta}_1)$ und der Schätzer $\hat{\sigma}^2$ sind stoch.unabhängig.

Konfidenzintervalle für β_0 und β_1

Gegeben dem einfachen linearen Modell mit $\varepsilon_i \sim \mathcal{N}(0, \sigma^2)$, gilt für $\hat{\beta}_1$ und $\hat{\beta}_0$

$$\frac{\hat{\beta}_1 - \beta_1}{\hat{\sigma}_{\hat{\beta}_1}} \sim t_{n-2} \text{ mit } \hat{\sigma}_{\hat{\beta}_1} := \sqrt{\frac{\hat{\sigma}^2}{\sum_{i=1}^n (x_i - \bar{x})^2}}$$

$$\frac{\hat{\beta}_0 - \beta_0}{\hat{\sigma}_{\hat{\beta}_0}} \sim t_{n-2} \text{ mit } \hat{\sigma}_{\hat{\beta}_0} := \sqrt{\hat{\sigma}^2 \frac{\sum_{i=1}^n x_i^2}{n \sum_{i=1}^n (x_i - \bar{x})^2}}$$

Damit können wir Konfidenzintervalle zum Niveau $1 - \alpha$ für β_1 und β_0 erzeugen:

$$[\hat{\beta}_1 - \hat{\sigma}_{\hat{\beta}_1} t_{1-\alpha/2}(n-2); \hat{\beta}_1 + \hat{\sigma}_{\hat{\beta}_1} t_{1-\alpha/2}(n-2)]$$

$$[\hat{\beta}_0 - \hat{\sigma}_{\hat{\beta}_0} t_{1-\alpha/2}(n-2); \hat{\beta}_0 + \hat{\sigma}_{\hat{\beta}_0} t_{1-\alpha/2}(n-2)]$$

Quadratsummenzerlegung

Gegeben sei ein einfaches lineares Modell mit $\varepsilon_i \sim \mathcal{N}(0, \sigma^2)$ und $\hat{Y}_i := \hat{\beta}_0 + \hat{\beta}_1 x_i$. Dann gilt

$$\underbrace{\sum_{i=1}^n (Y_i - \bar{Y})^2}_{\text{SST}} = \underbrace{\sum_{i=1}^n (Y_i - \hat{Y}_i)^2}_{\text{SSE}} + \underbrace{\sum_{i=1}^n (\hat{Y}_i - \bar{Y})^2}_{\text{SSM}}$$

SST(otal): Gesamtstreuung von Y
SSE(rror): Streuung der Residuen
SSM(odel): Streuung, die das Modell erklärt

Bestimmtheitsmaß

Unter Verwendung der obigen Notation definieren wir das **Bestimmtheitsmaß** als

$$R^2 = \frac{\text{SSM}}{\text{SST}} = 1 - \frac{\text{SSE}}{\text{SST}}.$$

Es gilt

$$R^2 = r_{xY}^2 = \frac{S_{xY}}{S_x S_Y},$$

wobei r_{xY} der Bravais-Pearson Korrel.koeffizient ist.

Interpretation von R^2

- R^2 beschreibt den Anteil der Varianz von Y , die durch x erklärt wird.
- R ist invariant gegenüber linearen linearen Transformationen von x und Y .
- R ist symmetrisch bzgl. x und Y .
- ! R^2 hängt auch von der Streuung von x in der Stichprobe ab.

Prognosewert

Gegeben sei ein einfaches lineares Modell mit $\varepsilon_i \sim \mathcal{N}(0, \sigma^2)$ und $\hat{Y}_i := \hat{\beta}_0 + \hat{\beta}_1 x_i$, $i = 1, \dots, n$. Sei nun eine weitere Beobachtung x_{n+1} mit zugehörigem $Y_{n+1} = \beta_0 + \beta_1 x_{n+1} + \varepsilon_{n+1}$ gegeben. Der **Prognosewert von Y_{n+1}** ist definiert als $\hat{Y}_{n+1} = \hat{\beta}_0 + \hat{\beta}_1 x_{n+1}$

Prognosefehler

Gegeben sei ein einfaches lineares Modell, sowie eine weitere Beobachtung x_{n+1} mit zugehörigem Y_{n+1} sowie der Prognosewert \hat{Y}_{n+1} . Dann gilt

$$E(\hat{Y}_{n+1} - Y_{n+1}) = 0$$

$$V(\hat{Y}_{n+1} - Y_{n+1}) = \sigma^2 \left[1 + \frac{1}{n} + \frac{(x_{n+1} - \bar{x})^2}{\sum_{i=1}^n (x_i - \bar{x})^2} \right]$$

Prognoseintervall

Gegeben sei ein einfaches lineares Modell, sowie eine weitere Beobachtung x_{n+1} mit zugehörigem Y_{n+1} sowie der Prognosewert \hat{Y}_{n+1} . Dann können wir für Y_{n+1} ein Konfidenzintervall zum Niveau $1 - \alpha$ konstruieren:

$$[\hat{Y}_{n+1} - \hat{\sigma}_{\hat{Y}_{n+1}} t_{1-\alpha/2}(n-2); \hat{Y}_{n+1} + \hat{\sigma}_{\hat{Y}_{n+1}} t_{1-\alpha/2}(n-2)]$$

mit

$$\hat{\sigma}_{\hat{Y}_{n+1}} = \hat{\sigma}^2 \left[1 + \frac{1}{n} + \frac{(x_{n+1} - \bar{x})^2}{\sum_{i=1}^n (x_i - \bar{x})^2} \right].$$

R-Code

```
# simuliere aus einfachem lin. Modell
beta0 <- 3
beta1 <- 1
sigma <- 2
x <- seq(from = 0, to = 10, by = 0.5)
e <- rnorm(length(x), sd = sigma)
y <- beta0 + beta1 * x + e
dat <- data.frame(x, y)

# Lineares Modell erzeugen
reg = lm(y ~ x, data = dat)
summary(reg)

# Konfidenzintervalle
confint(reg, level = 0.95)
```

Interpretation von transformierten Modellen

- Log-Log-Modell:

$$\log(Y_i) = \beta_0 + \beta_1 \log(x_i) + \varepsilon_i$$

Wenn x_i um den Faktor a steigt, dann steigt Y_i im Erwartungswert um den Faktor $a^{\beta_1} = e^{\beta_1 \log(a)}$.

Alternativ: Wenn x_i um 1% steigt, dann steigt Y_i im Erwartungswert um $(e^{\beta_1 \log(1.01)} - 1)\%$.

- Linear-Log-Modell:

$$Y_i = \beta_0 + \beta_1 \log(x_i) + \varepsilon_i$$

Wenn x_i um $p\%$ steigt, dann steigt Y_i im Erwartungswert um $\beta_1 \cdot \log(1 + p)\%$.

Alternativ: Wenn x_i um 1% steigt, dann steigt Y_i im Erwartungswert um approximativ β_1 Einheiten.

- Log-Linear-Modell:

$$\log(Y_i) = \beta_0 + \beta_1 x_i + \varepsilon_i$$

Wenn x_i um eine Einheit steigt, dann steigt Y_i im Erwartungswert um e^{β_1} Einheiten.

Vorlesung

R^2 ist abhängig von X . Das heißt über mehrere Studien hinweg, die das gleiche messen, ist R^2 nur vergleichbar, wenn auch X vergleichbar ist. Je sicherer wir mit unserem Schätzer sein wollen, desto höher sollten wir die Varianz von X einstellen. Gegeben, dass der Zusammenhang tatsächlich linear ist, würde eine höhere Varianz von X zu einer geringeren Varianz von $\hat{\beta}_1$ führen.

Im multiplen Reg.modell ist es KEINE Annahme, dass x_i, x_j unabhängig voneinander sind. Es wäre nur praktisch für die Interpretation der Effekte. Das „magische“ am multiplen Reg.modell ist, dass ich für verschiedene Größen kontrollieren/korrigieren kann.

Erwartungstreue gilt auch bei Abhängigkeit und normalverteilt ist nicht nötig. Varianzformel benötigt Unabhängigkeit.

Kapitel 2 - Das multiple lineare Regressionsmodell

Multiple lineares Regressionsmodell

Das **multiple lineare Regressionsmodell** hat die Form

$$Y_i = \beta_0 + \underbrace{\beta_1 x_{i1} + \dots + \beta_p x_{ip}}_{\mathbf{x}_i^\top = (1, x_{i1}, \dots, x_{ip})} + \varepsilon_i; i = 1, \dots, n$$

oder in Matrix-Vektor Notation: $\mathbf{Y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}$ mit

$$\mathbf{Y} = \begin{pmatrix} Y_1 \\ \vdots \\ Y_n \end{pmatrix}, \mathbf{X} = \begin{pmatrix} 1 & x_{11} & \dots & x_{1p} \\ \vdots & \vdots & \ddots & \vdots \\ 1 & x_{n1} & \dots & x_{np} \end{pmatrix},$$

$$\boldsymbol{\beta} = \begin{pmatrix} \beta_0 \\ \vdots \\ \beta_p \end{pmatrix}, \boldsymbol{\varepsilon} = \begin{pmatrix} \varepsilon_1 \\ \vdots \\ \varepsilon_n \end{pmatrix}.$$

Wir nehmen dabei an, dass $\mathbf{X} \in \mathbb{R}^{n \times (p+1)}$ eine feste Design-Matrix ist und dass $\boldsymbol{\varepsilon} \sim \mathcal{N}(\mathbf{0}, \sigma^2 \mathbf{I})$. Wir definieren außerdem $p' := p + 1$.

Kleinste Quadrate (KQ) Schätzer

Wir schätzen den Parameter(vektor) $\boldsymbol{\beta}$ durch

$$\hat{\boldsymbol{\beta}} = \arg \min_{\boldsymbol{\beta} \in \mathbb{R}^{p+1}} (\mathbf{Y} - \mathbf{X}\boldsymbol{\beta})^\top (\mathbf{Y} - \mathbf{X}\boldsymbol{\beta}) \quad (2)$$

und nennen $\hat{\boldsymbol{\beta}}$ den **KQ-Schätzer von $\boldsymbol{\beta}$** und $\hat{\varepsilon}_i := Y_i - \mathbf{x}_i^\top \hat{\boldsymbol{\beta}}$ die **Residuen**.

Existenz und Berechnung vom KQ Schätzer

Der KQ-Schätzer existiert und ist eindeutig, falls $\mathbf{X}^\top \mathbf{X}$ invertierbar ist. Dieser lässt sich berechnen als

$$\hat{\boldsymbol{\beta}} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{Y}$$

Durch differenzieren von der Gleichung (2) erhält man $\hat{\boldsymbol{\beta}}$ als Lösung der **Normalengleichung**

$$\mathbf{X}^\top \hat{\boldsymbol{\varepsilon}} = 0$$

Interpretation der Modellparameter

- Y_i hängt linear von x_{i1}, \dots, x_{in} ab.
- Steigt x_k um eine Einheit, so steigt Y (ceteris paribus) im Erwartungswert um β_k Einheiten, **wenn** alle anderen x -Variablen festgehalten werden.
- !** β_k charakterisiert den Einfluss von x_k unter Berücksichtigung der übrigen Variablen (Confounder-Korrektur). Das heißt, dass in einem einfachen linearen Regressionsmodell mit $Y_i = \beta_0 + \beta'_k x_{ik} + \varepsilon_i$ wäre im Allgemeinen $\beta'_k \neq \beta_k$.

Eigenschaften des KQ-Schätzers

Gegeben dem multiplen linearen Modell, gilt für den KQ-Schätzer $\hat{\boldsymbol{\beta}}$

- Erwartungstreue: $\mathbb{E}(\hat{\boldsymbol{\beta}}) = \boldsymbol{\beta}$.
! Gilt auch ohne die Annahme $\boldsymbol{\varepsilon} \sim \mathcal{N}(\mathbf{0}, \sigma^2 \mathbf{I})$, solange $\mathbb{E}(\boldsymbol{\varepsilon}) = \mathbf{0}$
- $\mathbb{V}(\hat{\boldsymbol{\beta}}) = \sigma^2 (\mathbf{X}^\top \mathbf{X})^{-1}$.
! Gilt auch ohne die Annahme $\boldsymbol{\varepsilon} \sim \mathcal{N}(\mathbf{0}, \sigma^2 \mathbf{I})$, solange $\text{Cov}(\boldsymbol{\varepsilon}) = \sigma^2 \mathbf{I}$
- $\hat{\boldsymbol{\beta}} \sim \mathcal{N}(\boldsymbol{\beta}, \sigma^2 (\mathbf{X}^\top \mathbf{X})^{-1})$

Hat-Matrix und Residualmatrix

Gegeben dem multiplen linearen Modell mit $\text{rang}(\mathbf{X}) = p'$ gilt

$$\hat{\mathbf{Y}} := \mathbf{X} \underbrace{(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{Y}}_{\hat{\boldsymbol{\beta}}}$$


$$\mathbf{P} := \underbrace{\mathbf{X} (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top}_{n \times n}$$

$$\hat{\boldsymbol{\varepsilon}} = \mathbf{Y} - \hat{\mathbf{Y}} = (\mathbf{I} - \mathbf{P})\mathbf{Y}$$

$$\mathbf{Q} := \mathbf{I} - \mathbf{P}$$

\mathbf{P} heißt **Hat-Matrix** und \mathbf{Q} heißt **Residualmatrix**.

Geometrische Interpretation



Die KQ-Schätzung ist eine orthogonale Projektion von \mathbf{Y} auf den von den \mathbf{x} -Vektoren aufgespannten Unterraum.

Eigenschaften von \mathbf{P} und \mathbf{Q}

Die Hat-Matrix \mathbf{P} und die Residualmatrix \mathbf{Q} sind Projektionsmatrizen und zueinander orthogonal:

$$\mathbf{P}^\top = \mathbf{P} \text{ und } \mathbf{P}^2 = \mathbf{P}$$

$$\mathbf{Q}^\top = \mathbf{Q} \text{ und } \mathbf{Q}^2 = \mathbf{Q}$$

$$\mathbf{P}\mathbf{Q} = \mathbf{Q}\mathbf{P} = \mathbf{0}.$$

Daraus folgt

$$\mathbb{V}(\hat{\mathbf{Y}}) = \sigma^2 \mathbf{P}$$

$$\mathbb{V}(\hat{\boldsymbol{\varepsilon}}) = \sigma^2 \mathbf{Q}, \text{ da } \hat{\boldsymbol{\varepsilon}} = \mathbf{Q}\boldsymbol{\varepsilon}$$

Schätzer für σ^2

Gegeben dem multiplen linearen Modell, gilt

$$\hat{\sigma}^2 := \frac{\hat{\boldsymbol{\varepsilon}}^\top \hat{\boldsymbol{\varepsilon}}}{n - (p + 1)} = \frac{1}{n - (p + 1)} \sum_{i=1}^n \hat{\varepsilon}_i^2$$

ist ein erwartungstreuer Schätzer von σ^2 .

! Gilt auch ohne die Annahme $\boldsymbol{\varepsilon} \sim \mathcal{N}(\mathbf{0}, \sigma^2 \mathbf{I})$, solange $\mathbb{E}(\boldsymbol{\varepsilon}) = \mathbf{0}$ und $\text{Cov}(\boldsymbol{\varepsilon}) = \sigma^2 \mathbf{I}$

Kapitel 3 - Quadratsummenzerlegung und statistische Inferenz im multiplen linearen Regressionsmodell

Quadratsummenzerlegung

Gegeben sei das multiple lineare Regressionsmodell mit $\text{rang}(\mathbf{X}) = p'$. Dann gilt

$$\underbrace{(\mathbf{Y} - \bar{\mathbf{Y}})^\top (\mathbf{Y} - \bar{\mathbf{Y}})}_{SST} = \underbrace{(\mathbf{Y} - \hat{\mathbf{Y}})^\top (\mathbf{Y} - \hat{\mathbf{Y}})}_{SSE} + \underbrace{(\hat{\mathbf{Y}} - \bar{\mathbf{Y}})^\top (\hat{\mathbf{Y}} - \bar{\mathbf{Y}})}_{SSM}.$$

SST(otal):	Gesamt-Quadratsumme (korrigiert)
SSE(rror):	Fehler-Quadratsumme
SSM(odell):	Modell-Quadratsumme

Quadratsummenzerlegung ohne β_0

Gegeben sei das multiple lineare Regressionsmodell mit, aber ohne Absolutglied β_0 . Dann gilt

$$\underbrace{\mathbf{Y}^\top \mathbf{Y}}_{SST^*} = \underbrace{(\mathbf{Y} - \hat{\mathbf{Y}})^\top (\mathbf{Y} - \hat{\mathbf{Y}})}_{SSE} + \underbrace{\hat{\mathbf{Y}}^\top \hat{\mathbf{Y}}}_{SSM^*}.$$

SST*:	Gesamt-Quadratsumme (nicht korrigiert)
SSE:	Fehler-Quadratsumme (wie zuvor)
SSM*:	Modell-Quadratsumme (nicht korrigiert)

Erwartungswerte der Quadratsummen

Gegeben sei das multiple lineare Regressionsmodell mit den üblichen Annahmen. Wir definieren

$$\mathbf{e} = \begin{pmatrix} 1 \\ \vdots \\ 1 \end{pmatrix} \text{ und } \mathbf{P}_e = \mathbf{e}(\mathbf{e}^\top \mathbf{e})^{-1} \mathbf{e}^\top \text{ und } \mathbf{Q}_e = \mathbf{I} - \mathbf{P}_e.$$

Dann gilt

$$\begin{aligned} \mathbb{E}(SST^*) &= \sigma^2 n + \beta^\top \mathbf{X}^\top \mathbf{X} \beta \\ \mathbb{E}(SST) &= \sigma^2 (n - 1) + \beta^\top (\mathbf{Q}_e \mathbf{X})^\top (\mathbf{Q}_e \mathbf{X}) \beta \\ \mathbb{E}(SSE) &= \sigma^2 (n - p') \\ \mathbb{E}(SSM^*) &= \sigma^2 p' + \beta^\top \mathbf{X}^\top \mathbf{X} \beta \\ \mathbb{E}(SSM) &= \sigma^2 (p' - 1) + \beta^\top (\mathbf{Q}_e \mathbf{X})^\top (\mathbf{Q}_e \mathbf{X}) \beta \end{aligned}$$

Wir können diese Eigenschaften zur Konstruktion von Tests verwenden. Es gilt nämlich unter anderem

$$\begin{aligned} \beta &= 0 \implies \mathbb{E}(SST^*) = \sigma^2 n \\ \beta_1 = \dots = \beta_p &= 0 \implies \mathbb{E}(SSM) = \sigma^2 (p' - 1) \end{aligned}$$

Chi-Quadrat Verteilung

Sei $\mathbf{Z} \sim \mathcal{N}_n(\boldsymbol{\mu}, \mathbf{I})$, so heißt $\mathbf{W} = \mathbf{Z}^\top \mathbf{Z} = \sum_{i=1}^n Z_i^2$ (nicht-zentral) **Chi-Quadrat-verteilt** und wir schreiben

$$W \sim \chi^2(n, \delta).$$

Wir nennen n die **Zahl der Freiheitsgrade** und $\delta = \boldsymbol{\mu}^\top \boldsymbol{\mu}$ den **Nicht-Zentralitätsparameter**. Es gilt

$$\begin{aligned} \mathbb{E}(W) &= n + \delta \\ \mathbb{V}(W) &= 2n + 4\delta \end{aligned}$$

t-Verteilung

Seien $Z \sim \mathcal{N}(\delta, 1)$ und $W \sim \chi^2(n, 0)$ unabhängig. Dann heißt $T = \frac{Z}{\sqrt{\frac{W}{n}}}$ (nicht-zentral) **t-verteilt** mit n **Freiheitsgraden** und **Nicht-Zentralitätsparameter** δ und wir schreiben

$$T \sim t(n, \delta).$$

Es gilt

$$\mathbb{E}(T) = \delta \sqrt{\frac{n}{2}} \frac{\Gamma(\frac{n-1}{2})}{\Gamma(\frac{n}{2})} \text{ für } n > 1$$

F-Verteilung

Sei $W_1 \sim \chi^2(n_1, \delta)$ und $W_2 \sim \chi^2(n_2, 0)$ unabhängig. Dann heißt $X = \frac{W_1/n_1}{W_2/n_2}$ (nicht-zentral) **F-verteilt** mit n_1 und n_2 **Freiheitsgraden** und **Nicht-Zentralitätsparameter** δ und wir schreiben

$$X \sim F(n_1, n_2, \delta).$$

Es gilt

$$\mathbb{E}(X) = \frac{n_2 + \frac{n_2 \delta}{n_1}}{n_2 - 2} \text{ für } n_2 > 2$$

Kapitel 4 - Diskrete Einflußgrößen

Kodierung

Sei C eine nominale Variable mit K Ausprägungen.

Dummy/Referenz-Kodierung:

Wir definieren K neue Variablen Z_1, \dots, Z_K als

$$Z_k(C) = \begin{cases} 1, & \text{falls } C = k \\ 0, & \text{sonst} \end{cases}$$

Z_1, \dots, Z_K sind abhängig, da $Z_K = 1 - \sum_{k=1}^{K-1} Z_k$

Effekt-Kodierung: Wir definieren $K - 1$ neue Variablen Z_1^e, \dots, Z_{K-1}^e als

$$Z_k^e(C) = \begin{cases} 1, & \text{falls } C = k \\ -1, & \text{falls } C = K \\ 0, & \text{sonst} \end{cases}$$

Note: $Z_k(C) = \begin{pmatrix} Z_k(C_1) \\ \vdots \\ Z_k(C_n) \end{pmatrix}$ und $Z_k^e(C) = \begin{pmatrix} Z_k^e(C_1) \\ \vdots \\ Z_k^e(C_n) \end{pmatrix}$

Setup einfache Varianzanalyse

Im folgenden betrachten wir die einfache Varianzanalyse mit nur einer diskreten Einflußgröße $C = \begin{pmatrix} C_1 \\ \vdots \\ C_n \end{pmatrix}$ mit K Ausprägungen. Sei n_k dabei die Anzahl der Beobachtungen mit $C_i = k$.

Mittelwertsmodell

Das **Mittelwertsmodell** ist gegeben durch

$$Y_{kl} = \mu_k + \epsilon_{kl} \quad l = 1, \dots, n_k \quad k = 1, \dots, K$$

oder in Matrix-Vektor Notation:

$$Y = (Z_1(C) \cdots Z_K(C)) \begin{pmatrix} \mu_1 \\ \vdots \\ \mu_K \end{pmatrix} + \epsilon$$

Bei dem Mittelwertsmodell gibt es keinen Intercept und die μ_k sind die Mittelwerte der k -ten Gruppe. Der Effekt der k -ten Gruppe ist also μ_k .

Mittelwertsmodell Beispiel

Für $K = 3$ Ausprägungen und $n_k = 2$ für alle $k = 1, 2, 3$ erhalten wir als Mittelwertsmodell:

$$Y = \begin{pmatrix} Y_{11} \\ Y_{12} \\ Y_{21} \\ Y_{22} \\ Y_{31} \\ Y_{32} \end{pmatrix} = \begin{pmatrix} 1 & 0 & 0 \\ 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \\ 0 & 0 & 1 \end{pmatrix} \begin{pmatrix} \mu_1 \\ \mu_2 \\ \mu_3 \end{pmatrix} + \begin{pmatrix} \epsilon_{11} \\ \epsilon_{12} \\ \epsilon_{21} \\ \epsilon_{22} \\ \epsilon_{31} \\ \epsilon_{32} \end{pmatrix}$$

Modell mit Effekt-Kodierung

Das **Modell mit Effekt-Kodierung** ist gegeben durch

$$Y_{kl} = \mu + \tau_k + \epsilon_{kl}; \quad \tau_K = - \sum_{k=1}^{K-1} \tau_k$$

für $l = 1, \dots, n_k \quad k = 1, \dots, K$ oder in Matrix-Vektor Notation:

$$Y = (e \ Z_1^e(C) \cdots Z_{K-1}^e(C)) \begin{pmatrix} \mu \\ \tau_1 \\ \vdots \\ \tau_{K-1} \end{pmatrix} + \epsilon$$

Bei dem Modell mit Effekt-Kodierung gibt es einen Intercept μ und die τ_k sind die Abweichungen der k -ten Gruppe vom Gesamtmittelwert bzw. vom Intercept μ . Der Effekt der k -ten Gruppe ist also $\mu + \tau_k$.

Modell mit Effekt-Kodierung Beispiel

Für $K = 3$ Ausprägungen und $n_k = 2$ für alle $k = 1, 2, 3$ erhalten wir als Modell mit Effekt-Kodierung:

$$Y = \begin{pmatrix} Y_{11} \\ Y_{12} \\ Y_{21} \\ Y_{22} \\ Y_{31} \\ Y_{32} \end{pmatrix} = \begin{pmatrix} 1 & 1 & 0 \\ 1 & 1 & 0 \\ 1 & 0 & 1 \\ 1 & 0 & 1 \\ 1 & -1 & -1 \\ 1 & -1 & -1 \end{pmatrix} \begin{pmatrix} \mu \\ \tau_1 \\ \tau_2 \end{pmatrix} + \begin{pmatrix} \epsilon_{11} \\ \epsilon_{12} \\ \epsilon_{21} \\ \epsilon_{22} \\ \epsilon_{31} \\ \epsilon_{32} \end{pmatrix}$$

Modell mit Referenz-Kodierung

Das **Modell mit Referenz-Kodierung** ist gegeben durch

$$Y_{kl} = \mu_K + \tau_k + \epsilon_{kl}; \quad \tau_K = 0$$

für $l = 1, \dots, n_k \quad k = 1, \dots, K$ oder in Matrix-Vektor Notation:

$$Y = (e \ Z_1(C) \cdots Z_{K-1}(C)) \begin{pmatrix} \mu_K \\ \tau_1 \\ \vdots \\ \tau_{K-1} \end{pmatrix} + \epsilon$$

Beim Modell mit Referenz-Kodierung gibt es einen Intercept μ_K der den Mittelwert der K -ten Gruppe angibt und die τ_k sind die Abweichungen der k -ten Gruppe vom Mittelwert der K -ten Referenz-Gruppe. Der Effekt der k -ten Gruppe ist also $\mu_K + \tau_k$ für $k = 1, \dots, K - 1$ und μ_K für $k = K$.

Modell mit Referenz-Kodierung Beispiel

Für $K = 3$ Ausprägungen und $n_k = 2$ für alle $k = 1, 2, 3$ erhalten wir als Modell mit Referenz-Kodierung:

$$Y = \begin{pmatrix} Y_{11} \\ Y_{12} \\ Y_{21} \\ Y_{22} \\ Y_{31} \\ Y_{32} \end{pmatrix} = \begin{pmatrix} 1 & 1 & 0 \\ 1 & 1 & 0 \\ 1 & 0 & 1 \\ 1 & 0 & 1 \\ 1 & 0 & 0 \\ 1 & 0 & 0 \end{pmatrix} \begin{pmatrix} \mu_3 \\ \tau_1 \\ \tau_2 \end{pmatrix} + \begin{pmatrix} \epsilon_{11} \\ \epsilon_{12} \\ \epsilon_{21} \\ \epsilon_{22} \\ \epsilon_{31} \\ \epsilon_{32} \end{pmatrix}$$

Bemerkungen-Kodierung

Alle Modellvarianten führen zur gleichen Modellanpassung (R^2). Die Parameter haben aber unterschiedliche Interpretationen. Parameter und deren Schätzer sind aber ineinander umrechenbar.

Wir können folgende Nullhypothese für den Effekt von C testen:

Mittelwertsmodell	$H_0 : \mu_1 = \dots = \mu_K$
Effekt-Kodierung	$H_0 : \tau_1 = \dots = \tau_{K-1} = 0$
Referenz-Kodierung	$H_0 : \tau_1 = \dots = \tau_{K-1} = 0$

Setup zweifaktorielle Varianzanalyse

Im folgenden betrachten wir zwei diskrete Einflußgrößen $\mathbf{C} = \begin{pmatrix} C_1 \\ \vdots \\ C_n \end{pmatrix}$ und $\mathbf{D} = \begin{pmatrix} D_1 \\ \vdots \\ D_n \end{pmatrix}$ mit K_C bzw. K_D Ausprägungen. Sei $n_{k,l}$ dabei die Anzahl der Beobachtungen mit $C_i = k$ und $D_j = l$.

! Hier ist die Mittelwertsdarstellung bzw. das Mittelwertsmodell nicht möglich, da dieser davon abhängig ist, welche Variable zuerst kodiert wird.

Modell mit Effekt-Kodierung (mehrfaktoriell)

Das **Modell mit Effekt-Kodierung** ist gegeben durch

$$\mathbf{Y} = (\mathbf{e} \quad \mathbf{Z}_1^e(\mathbf{C}) \cdots \mathbf{Z}_{K_C-1}^e(\mathbf{C}) \quad \mathbf{Z}_1^e(\mathbf{D}) \cdots \mathbf{Z}_{K_D-1}^e(\mathbf{D})) \begin{pmatrix} \mu \\ \tau_1 \\ \vdots \\ \tau_{K_C-1} \\ \gamma_1 \\ \vdots \\ \gamma_{K_D-1} \end{pmatrix} + \epsilon$$

mit $\tau_{K_C} = -\sum_{k=1}^{K_C-1} \tau_k$ und $\gamma_{K_D} = -\sum_{k=1}^{K_D-1} \gamma_k$.

Bei dem Modell mit Effekt-Kodierung gibt es einen Intercept μ und die τ_k und γ_l sind die Abweichungen der Gruppe mit $C = k$ bzw. $D = l$ vom Gesamtmittelwert bzw. vom Intercept μ .

Modell mit Referenz-Kodierung (mehrfakt.)

Das **Modell mit Referenz-Kodierung** ist gegeben durch

$$\mathbf{Y} = (\mathbf{e} \quad \mathbf{Z}_1(\mathbf{C}) \cdots \mathbf{Z}_{K_C-1}(\mathbf{C}) \quad \mathbf{Z}_1(\mathbf{D}) \cdots \mathbf{Z}_{K_D-1}(\mathbf{D})) \begin{pmatrix} \mu \\ \tau_1 \\ \vdots \\ \tau_{K_C-1} \\ \gamma_1 \\ \vdots \\ \gamma_{K_D-1} \end{pmatrix} + \epsilon$$

mit $\tau_{K_C} = 0$ und $\gamma_{K_D} = 0$.

Bei dem Modell mit Referenz-Kodierung gibt es einen Intercept μ der den Mittelwert der Gruppe mit $C = K_C$ und $D = K_D$ angibt und die τ_k und γ_l sind die Abweichungen der Gruppe mit $C = k$ bzw. $D = l$ vom Mittelwert der Gruppe mit $C = K_C$ und $D = K_D$.

Kodierung Vergleich (mehrfaktoriell) Beispiel

Sei $K_C = 2$ und $K_D = 3$ mit $n_{k,l} = 2$ für alle $k = 1, 2, 3$ und $l = 1, 2$.

Dann erhalten wir als Designmatrix für das Modell mit

Effekt-Kodierung:


$$\mathbf{X} = (\mathbf{e} \quad \mathbf{Z}_1^e(\mathbf{C}) \quad \mathbf{Z}_1^e(\mathbf{D}) \quad \mathbf{Z}_2^e(\mathbf{D})) = \begin{pmatrix} 1 & 1 & 1 & 0 \\ 1 & 1 & 1 & 0 \\ 1 & 1 & 0 & 1 \\ 1 & 1 & 0 & 1 \\ 1 & 1 & -1 & -1 \\ 1 & 1 & -1 & -1 \\ 1 & -1 & 1 & 0 \\ 1 & -1 & 1 & 0 \\ 1 & -1 & 0 & 1 \\ 1 & -1 & 0 & 1 \\ 1 & -1 & -1 & -1 \\ 1 & -1 & -1 & -1 \end{pmatrix}$$

Referenz-Kodierung:

$$\mathbf{X} = (\mathbf{e} \quad \mathbf{Z}_1(\mathbf{C}) \quad \mathbf{Z}_1(\mathbf{D}) \quad \mathbf{Z}_2(\mathbf{D})) = \begin{pmatrix} 1 & 1 & 1 & 0 \\ 1 & 1 & 1 & 0 \\ 1 & 1 & 0 & 1 \\ 1 & 1 & 0 & 1 \\ 1 & 1 & 0 & 0 \\ 1 & 1 & 0 & 0 \\ 1 & 0 & 1 & 0 \\ 1 & 0 & 1 & 0 \\ 1 & 0 & 0 & 1 \\ 1 & 0 & 0 & 1 \\ 1 & 0 & 0 & 0 \\ 1 & 0 & 0 & 0 \end{pmatrix}$$

Visualisierung Beispiel

Wir können die Effekte visualisieren, indem wir die Mittelwerte der Gruppen betrachten:



Note: „Faktor 2“ ist hier D und „A1“ und „A2“ sind hier $C = 1$ und $C = 2$. Auf der y-Achse ist der Mittelwert der Gruppe dargestellt.

In beiden Fällen werden folgende Gleichungen erfüllt:

$$\begin{aligned} \hat{\mu} + \hat{\tau}_1 + \hat{\gamma}_1 &= 4 & \hat{\mu} + \hat{\tau}_2 + \hat{\gamma}_1 &= 0 \\ \hat{\mu} + \hat{\tau}_1 + \hat{\gamma}_2 &= 5 & \hat{\mu} + \hat{\tau}_2 + \hat{\gamma}_2 &= 1 \\ \hat{\mu} + \hat{\tau}_1 + \hat{\gamma}_3 &= 0 & \hat{\mu} + \hat{\tau}_2 + \hat{\gamma}_3 &= -4 \end{aligned}$$

Effekt-Kodierung:

$$\begin{aligned} \hat{\mu} &= 1 & \hat{\gamma}_1 &= 1 \\ \hat{\tau}_1 &= 2 & \hat{\gamma}_2 &= 2 \\ \hat{\tau}_2 &= -2 & \hat{\gamma}_3 &= -3 \end{aligned}$$

! Der Verlauf für $C = 1$ und $C = K_C = 2$ ist parallel mit Abstand $\hat{\tau}_1 - \hat{\tau}_2$.

Referenz-Kodierung:

$$\begin{aligned} \hat{\mu} &= -4 & \hat{\gamma}_1 &= 4 \\ \hat{\tau}_1 &= 4 & \hat{\gamma}_2 &= 5 \\ \hat{\tau}_2 &= 0 & \hat{\gamma}_3 &= 0 \end{aligned}$$

! Der Verlauf für $C = 1$ und $C = K_C = 2$ ist parallel mit Abstand $\hat{\tau}_1$. Man beachte auch, dass sich die Schätzer direkt in dem Plot ablesen lassen.

Interaktion

In den obigen Modellen haben wir die Interaktion zwischen den Einflußgrößen C und D nicht berücksichtigt. Interaktion bedeutet, dass der Effekt von C von D abhängt und umgekehrt.

Beispiele:

- Die Wirkung des Medikaments ist bei Männern anders als bei Frauen.
- Die Wirkung des Medikaments ist bei jungen Menschen anders als bei alten Menschen.
- Die Wirkung des Lesetrainings ist bei guten Schülern geringer als bei schwachen Schülern.

! Der Begriff Interaktion ist in anderen Fachbereichen auch bekannt als Moderation (Psychologie), Synergieeffekte (Wirtschaft).

Wir können die Interaktion zwischen C und D berücksichtigen, indem wir die Effekte von C und D nicht additiv, sondern multiplikativ betrachten.

Interaktionsmodell (Effekt-Kodierung)

In dem **Modell mit Effekt-Kodierung und Interaktion** ist die Designmatrix gegeben durch die Spalten der Designmatrix aus dem Modell ohne Interaktion \mathbf{X}^e und zusätzlich die Spalten der Interaktionsterme:

$$\mathbf{Z}^e = (Z_1^e(C)Z_1^e(D) \cdots Z_1^e(C)Z_{K_D-1}^e(D) \cdots Z_{K_C-1}^e(C)Z_{K_D-1}^e(D))$$

Die Designmatrix ist also gegeben durch $(\mathbf{X}^e \quad \mathbf{Z}^e)$

Die Parameter sind gegeben durch $\mu \quad \tau_k \quad \gamma_l \quad (\tau\gamma)_{k,l}$ mit $k = 1, \dots, K_C - 1 \quad l = 1, \dots, K_D - 1$.

Die Modellgleichung ist gegeben durch

$$Y_{k,l} = \mu + \tau_k + \gamma_l + (\tau\gamma)_{k,l} + \epsilon_{k,l}$$

mit den Nebenbedingungen

$$\sum_{k=1}^{K_C-1} \tau_k = 0 \quad \text{und} \quad \sum_{l=1}^{K_D-1} \gamma_l = 0$$

sowie

$$\forall l : \sum_{k=1}^{K_C} (\tau\gamma)_{k,l} = 0 \quad \text{und} \quad \forall k : \sum_{l=1}^{K_D} (\tau\gamma)_{k,l} = 0$$

Interpretation Interaktion (Effekt-Kodierung)

- μ ist der Gesamtmittelwert.
- τ_k ist der Unterschied zwischen dem Mittelwert der Gruppe mit $C = k$ und dem Gesamtmittelwert.
- γ_l ist der Unterschied zwischen dem Mittelwert der Gruppe mit $D = l$ und dem Gesamtmittelwert.
- $(\tau\gamma)_{k,l}$ ist der Effekt der Interaktion auf die Basiseffekte τ_k und γ_l durch die Ausprägungen $C = k$ und $D = l$.

Interaktionsmodell (Referenz-Kodierung)

In dem **Modell mit Referenz-Kodierung und Interaktion** ist die Designmatrix gegeben durch die Spalten der Designmatrix aus dem Modell ohne Interaktion \mathbf{X} und zusätzlich die Spalten der Interaktionsterme:

$$\mathbf{Z} = (Z_1(C)Z_1(D) \cdots Z_1(C)Z_{K_D-1}(D) \cdots Z_{K_C-1}(C)Z_{K_D-1}(D))$$

Die Designmatrix ist also gegeben durch $(\mathbf{X} \quad \mathbf{Z})$.

Die Parameter sind gegeben durch $\mu \quad \tau_k \quad \gamma_l \quad (\tau\gamma)_{k,l}$ mit $k = 1, \dots, K_C - 1 \quad l = 1, \dots, K_D - 1$.

Die Modellgleichung ist gegeben durch

$$Y_{k,l} = \mu + \tau_k + \gamma_l + (\tau\gamma)_{k,l} + \epsilon_{k,l}$$

mit den Nebenbedingungen

$$\tau_{K_C} = 0 \quad \text{und} \quad \gamma_{K_D} = 0$$

sowie


$$\forall l : (\tau\gamma)_{K_C,l} = 0 \quad \text{und} \quad \forall k : (\tau\gamma)_{k,K_D} = 0$$

Interpret. Interaktion (Referenz-Kodierung)

- τ_k ist der Unterschied zwischen dem Mittelwert der Gruppe mit $C = k$ zu der Referenzgruppe mit $C = K_C$.
- γ_l ist der Unterschied zwischen dem Mittelwert der Gruppe mit $D = l$ zu der Referenzgruppe mit $D = K_D$.
- $(\tau\gamma)_{k,l}$ ist der Effekt der Interaktion auf die Basiseffekte τ_k und γ_l zur jeweiligen Referenzgruppe durch die Ausprägungen $C = k$ und $D = l$.

Visualisierung Beispiel

Wir können die Effekte visualisieren, indem wir die Mittelwerte der Gruppen betrachten:



Note: „Faktor 2“ ist hier D und „A1“ und „A2“ sind hier $C = 1$ und $C = 2$. Auf der y-Achse ist der Mittelwert der Gruppe dargestellt.

In beiden Fällen werden folgende Gleichungen erfüllt:

$$\begin{aligned} \hat{\mu} + \hat{\tau}_1 + \hat{\gamma}_1 + (\widehat{\tau\gamma})_{1,1} &= 2 \\ \hat{\mu} + \hat{\tau}_1 + \hat{\gamma}_2 + (\widehat{\tau\gamma})_{1,2} &= 5 \\ \hat{\mu} + \hat{\tau}_1 + \hat{\gamma}_3 + (\widehat{\tau\gamma})_{1,3} &= 2 \\ \hat{\mu} + \hat{\tau}_2 + \hat{\gamma}_1 + (\widehat{\tau\gamma})_{2,1} &= 2 \\ \hat{\mu} + \hat{\tau}_2 + \hat{\gamma}_2 + (\widehat{\tau\gamma})_{2,2} &= 1 \\ \hat{\mu} + \hat{\tau}_2 + \hat{\gamma}_3 + (\widehat{\tau\gamma})_{2,3} &= -6 \end{aligned}$$

Effekt-Kodierung:

$$\begin{aligned} \hat{\mu} &= 1 & \hat{\gamma}_1 &= 1 & (\widehat{\tau\gamma})_{1,1} &= -2 & (\widehat{\tau\gamma})_{2,1} &= 2 \\ \hat{\tau}_1 &= 2 & \hat{\gamma}_2 &= 2 & (\widehat{\tau\gamma})_{1,2} &= 0 & (\widehat{\tau\gamma})_{2,2} &= 0 \\ \hat{\tau}_2 &= -2 & \hat{\gamma}_3 &= -3 & (\widehat{\tau\gamma})_{1,3} &= 2 & (\widehat{\tau\gamma})_{2,3} &= -2 \end{aligned}$$

Referenz-Kodierung:

$$\begin{aligned} \hat{\mu} &= -6 & \hat{\gamma}_1 &= 8 & (\widehat{\tau\gamma})_{1,1} &= -2 & (\widehat{\tau\gamma})_{2,1} &= 0 \\ \hat{\tau}_1 &= 4 & \hat{\gamma}_2 &= 7 & (\widehat{\tau\gamma})_{1,2} &= 1 & (\widehat{\tau\gamma})_{2,2} &= 0 \\ \hat{\tau}_2 &= 0 & \hat{\gamma}_3 &= 0 & (\widehat{\tau\gamma})_{1,3} &= 0 & (\widehat{\tau\gamma})_{2,3} &= 0 \end{aligned}$$